Detectando la diabetes antes de que aparezca: un modelo predictivo con Inteligencia Artificial basado en la ENSANUT continua 2024.

Medina Mixtega Ángel Miguel, Mendez Damián Brandon Efren, Méndez Ortega Paula, Mota Barraza Moisés, Plascencia Arevalo Alberto

Samsung Innovation Campus

Reporte de presentación de objetivos: Proyecto de Inteligencia Artificial

Signal Lab (Equipo Núm. 1)

10 de abril de 2026

Detectando la diabetes antes de que aparezca: un modelo predictivo con Inteligencia Artificial basado en la ENSANUT continua 2024

En la actualidad, México atraviesa una emergencia sanitaria silenciosa que compromete la estabilidad de su sistema de salud y el bienestar de su población. De acuerdo con datos de la Secretaría de Salud, el país registra aproximadamente 169,425 nuevos diagnósticos de Diabetes Mellitus Tipo 2 (DMT2) cada año. Sin embargo, esta cifra es apenas la superficie de un problema mucho más profundo: la DMT2 no es solo una estadística médica, sino la principal causa de mortalidad y discapacidad a nivel nacional, representando una carga económica que consume una parte significativa del presupuesto destinado al sector salud.

El desafío crítico identificado por el equipo de Signal Lab no radica únicamente en la prevalencia de la enfermedad, sino en el momento del diagnóstico. Históricamente, la medicina ha operado bajo un modelo reactivo; es decir, se interviene cuando el paciente ya presenta sintomatología clara o complicaciones evidentes. Esta brecha diagnóstica se ve exacerbada por tres barreras estructurales:

1. Inaccesibilidad tecnológica y económica: las herramientas de monitoreo actuales dependen de infraestructura clínica y pruebas de laboratorio invasivas (como la medición de hemoglobina glucosilada o glucosa en ayunas), las cuales no son accesibles para gran parte de la población en entornos rurales o de escasos recursos.
2. La ventana invisible de la diabetes: debido a su naturaleza asintomática en etapas iniciales, millones de mexicanos ignoran sus factores de riesgo;

como el sedentarismo, la predisposición genética y los hábitos alimenticios, hasta que el daño orgánico (insuficiencia renal, retinopatía o neuropatía) es irreversible.

3. Saturación del sistema de salud: el enfoque actual sobrecarga las instituciones públicas, ya que la detección ocurre habitualmente en etapas avanzadas, donde el tratamiento es costoso, complejo y con menor probabilidad de éxito.

Ante este panorama, surge la necesidad imperante de democratizar el tamizaje médico. La propuesta de este proyecto representa un cambio de paradigma: transitar de la detección clínica reactiva al tamizaje preventivo predictivo. Mediante el uso de Inteligencia Artificial aplicada a la Encuesta Nacional de Salud y Nutrición (ENSANUT) Continua 2024, hemos desarrollado una solución que rompe la dependencia de los biomarcadores sanguíneos tradicionales.

Al procesar variables antropométricas y hábitos de vida a través de algoritmos de aprendizaje supervisado y no supervisado, el modelo de Signal Lab permite identificar individuos en riesgo en una etapa donde la intervención aún puede prevenir la transición a la enfermedad crónica. Este enfoque no solo busca salvar vidas, sino también optimizar los recursos del Estado, demostrando que la convergencia entre la ciencia de datos y la salud pública es la clave para enfrentar las crisis sanitarias del siglo XXI.

Objetivos del Proyecto

Para materializar esta propuesta, se establecieron los siguientes ejes rectores:

Objetivo General

Desarrollar y comparar modelos de aprendizaje automático (supervisado y no supervisado) para la predicción del riesgo de DMT2 en adultos mexicanos utilizando la ENSANUT Continua 2024, alcanzando un AUC-ROC mínimo de 0.70. Este umbral se establece con base en los benchmarks de la literatura epidemiológica para encuestas poblacionales sin biométricos de laboratorio, buscando optimizar la precisión de detección en etapas preventivas mediante métodos no invasivos.

Objetivos Específicos

1. Ingeniería de características y relevancia estadística: seleccionar y validar un conjunto de variables predictoras (antropométricas y clínicas) mediante análisis de importancia de características y pruebas de correlación, asegurando un Factor de Inflación de Varianza (VIF < 5) para garantizar la ausencia de multicolinealidad y la integridad de los datos.
2. Modelado y evaluación: evaluar algoritmos de ensamble (Random Forest y Gradient Boosting) mediante Validación Cruzada (10 - fold CV) y optimización de hiperparámetros (Grid Search), priorizando la métrica AUC-ROC para maximizar la capacidad de generalización y la detección preventiva de riesgos.
3. Segmentación y perfilamiento: implementar algoritmos de aprendizaje no supervisado (K-Means) evaluando su desempeño mediante métricas de cohesión (Silhouette Score y Calinski-Harabasz Index), con el fin de identificar y validar al menos tres perfiles diferenciados de riesgo metabólico en la población mexicana.

Metodología

La metodología se articuló a través de un pipeline de ciencia de datos riguroso, diseñado para transformar microdatos crudos en un dataset estructurado apto para el aprendizaje automático. Este proceso se dividió en las fases de adquisición, curación estructural, sincronización multimodal y preprocesamiento clínico.

Adquisición e Integración Multidimensional de Datos

Se realizó una integración de cinco módulos fundamentales de la ENSANUT Continua 2024 (Instituto Nacional de Salud Pública [INSP], 2024), construyendo un ecosistema de datos que permitió una visión holística del paciente. Los módulos integrados fueron:

- Antropometría (n = 17,597) : medidas físicas y tensión arterial.
- Salud de adultos: antecedentes patológicos y diagnósticos previos.
- Consumo de alimentos: patrones nutricionales y frecuencia de ingesta.
- Demografía: contexto socioeconómico y estructura del hogar.
- Biométricos (n = 9,401): datos de hemoglobina utilizados como validación diagnóstica (gold standard).

Para garantizar la integridad desde el origen, se desarrolló un algoritmo de carga robusta con manejo de excepciones. Este sistema automatizó la identificación de codificaciones (específicamente latin-1) y la remoción de caracteres Byte Order Mark (BOM), asegurando que la lectura de los metadatos fuera consistente en todas las etapas del modelado.

Ingeniería de Identificadores y Sincronización Multimodal

Uno de los mayores desafíos técnicos enfrentados fue la disparidad de formatos y la ausencia de una llave primaria única consistente en todos los cuestionarios. Para resolver este problema de integridad referencial, el equipo diseñó una Ingeniería de Identificadores Sintéticos siguiendo la estructura de codificación del INSP (2024). Se construyó una llave única denominada FOLIO_I mediante la concatenación algorítmica de tres variables de segmentación:

FOLIO_I = UPM + VIV_SEL + NUM_REN

Donde UPM representa la Unidad Primaria de Muestreo, VIV_SEL la vivienda seleccionada y NUM_REN el número de renglón del residente. Debido a discrepancias en la codificación de los sufijos en el módulo de Hemoglobina, se implementó una estrategia de normalización por truncamiento, recortando los identificadores a 13 caracteres para alinear las unidades de vivienda. Esta técnica de sincronización multimodal permitió rescatar una muestra robusta de 24,255 registros, garantizando la representatividad estadística de la población adulta mexicana.

Curación Estructural y Selección de Variables

Dada la naturaleza de los archivos comprimidos de la ENSANUT, se implementó un algoritmo de selección por peso volumétrico para identificar los datasets principales. Durante esta fase, se detectaron inconsistencias críticas en el módulo de Salud de Adultos, como encabezados desplazados y columnas sin etiqueta (Unnamed).

Para mitigar esto, se diseñó un flujo de reparación estructural dinámica que realineó las columnas mediante la identificación de llaves primarias, permitiendo una limpieza de metadatos agresiva. Posteriormente, se ejecutó una unión maestra (Inner Join) entre los módulos de Salud y Antropometría, seguida de un Left Join para enriquecer el dataset con variables nutricionales y biométricas, priorizando siempre la calidad de las variables predictoras.

Mediante un motor de búsqueda basado en patrones de texto y prefijos epidemiológicos, se extrajeron 55 variables clave. Estas fueron clasificadas en tres categorías esenciales para el modelo predictivo:

1. Indicadores antropométricos: peso, talla, tensión arterial (sistólica y diastólica en tres tomas) e Índice de Masa Corporal (IMC).
2. Variables de control: tiempos de entrevista y folios de seguimiento para asegurar la trazabilidad.
3. Datos clínicos: variables con prefijos AN y H, fundamentales para la construcción de un sistema de tamizaje no invasivo.

Para asegurar que los modelos de Machine Learning no fueran sesgados por datos erróneos o ruidos de campo, se aplicó una fase de limpieza robusta y filtrado biológico:

- Normalización numérica: estandarización de separadores decimales y eliminación de códigos de error epidemiológico (v.gr., el valor "999" en presión arterial, utilizado en campo para indicar datos faltantes según el manual del INSP [2024]).

- Validación de rangos fisiológicos: se establecieron límites estrictos basados en la literatura médica, como un rango de IMC entre 10 y 80 kg/m², eliminando outliers que no representaran realidades biológicas.
- Definición del target: se generó una variable de riesgo preliminar basada en el umbral de obesidad (IMC > 30), criterio alineado con las guías de la Organización Mundial de la Salud (OMS, 2021) para la identificación de riesgo metabólico temprano.

Identificación del Target Epidemiológico Mediante Escaneo Semántico

Uno de los hitos técnicos del proyecto fue la superación de un punto ciego en las variables directas de laboratorio. Ante la ausencia inicial de registros útiles bajo filtros estrictos de hemoglobina, se desarrolló un motor de escaneo global transversal a los cinco módulos de la encuesta.

Este motor analizó descriptores semánticos (v.gr., DIAB, AZUCAR, H03), logrando identificar la variable H0302 como el indicador clínico clave de diagnóstico previo de diabetes. Al decodificar estos valores binarios, el modelo evolucionó de un enfoque puramente biométrico a uno de clasificación supervisada basado en historial clínico reportado, enriqueciendo significativamente la precisión del sistema de tamizaje.

Ingeniería de Características y Análisis de Calidad

El dataset final presenta una distribución de clases óptima para el entrenamiento supervisado, con una prevalencia de DMT2 del 44.0%. Esta paridad estadística es

fundamental, ya que permite que los modelos de ensamble aprendan a identificar con equidad tanto los perfiles de riesgo como los saludables, minimizando el riesgo de falsos negativos.

Durante el análisis de calidad de los datos, se identificó una disparidad en la granularidad de las variables:

1. Pilares de cribado masivo: variables como el IMC y la Edad presentan un 0.0% de datos nulos, lo que las convierte en predictores altamente confiables para un despliegue a gran escala.
2. Variables clínicas de precisión: la presión arterial (sistólica y diastólica) presentó una ausencia de datos de entre el 45% y 70%.

Para potenciar la capacidad discriminatoria del modelo, el equipo de Signal Lab trascendió el uso de variables crudas mediante la creación de indicadores biomédicos avanzados. Se integró un set de siete variables predictoras, destacando dos innovaciones técnicas:

- Presión de pulso (PP): calculada mediante la fórmula PP = Sistólica - Diastólica. Este indicador es fundamental en la literatura clínica como predictor de rigidez arterial y riesgo cardiovascular, factores estrechamente ligados a la progresión de la DMT2.
- Variable de riesgo combinado (Edad x IMC): se desarrolló este término de interacción para capturar el efecto multiplicador del envejecimiento y el sobrepeso. Esta variable sintética permite al modelo ponderar de forma no lineal cómo el riesgo metabólico se intensifica con el paso del tiempo en pacientes con índices de masa corporal elevados.

Este set optimizado se aplicó a un dataset refinado de 3,949 registros, el cual mantiene una prevalencia balanceada de diabetes (38.8%), proporcionando una base sólida para el entrenamiento de algoritmos de ensamble sin sesgos de clase.

Estrategia de Modelado Multinivel

Para abordar la heterogeneidad en la disponibilidad de los datos, Signal Lab optó por un enfoque de Modelado Multinivel. Esta arquitectura permite una detección escalonada basada en el entorno de aplicación:

- Modelo general: basado exclusivamente en indicadores antropométricos con cobertura del 100% (ideal para aplicaciones móviles o tamizaje rápido en campo).
- Sub-modelo de validación clínica: un modelo especializado para registros que cuentan con datos de presión arterial, elevando la precisión diagnóstica en entornos donde se dispone de equipo médico básico.

Diseño del Pipeline de Aprendizaje Automátic.

Para garantizar la reproducibilidad y la integridad del modelo, se diseñó un Pipeline de Machine Learning automatizado. Este enfoque es crítico para evitar el data leakage, asegurando que las transformaciones aplicadas al conjunto de entrenamiento no se vean influenciadas por la información del conjunto de prueba. El flujo se estructuró de la siguiente manera:

- Imputación robusta de datos: ante la presencia de valores faltantes en variables clínicas, se implementó una estrategia de imputación diferenciada. Para las variables numéricas se utilizó la mediana, una medida de tendencia central menos

sensible a los valores atípicos (outliers) presentes en datos epidemiológicos. Para las variables categóricas, se empleó la moda.

- Normalización y escalamiento estándar: debido a las disparidades en las unidades de medida (v.gr., la presión arterial en mmHg frente al IMC en kg/m²), se aplicó un Standard Scaler. Esta técnica transforma las variables para que tengan una media de cero y una desviación estándar de uno, evitando que el algoritmo sesgue su importancia hacia variables con magnitudes numéricas mayores.
- Estratificación del dataset: se empleó una división (split) de 80% para entrenamiento y 20% para prueba. Para mitigar el sesgo de clase, se utilizó un muestreo estratificado que mantuvo la proporción exacta de casos de diabetes (38.8%) en ambos subconjuntos, garantizando una evaluación justa y representativa del desempeño real.

Optimización de Hiperparámetros y Validación Cruzada

El proceso de entrenamiento no se limitó a configuraciones por defecto. Se ejecutó una búsqueda exhaustiva de hiperparámetros mediante Grid Search, evaluando un espacio de búsqueda de 4,050 combinaciones de parámetros. Para asegurar la estabilidad del modelo y su capacidad de generalización ante nuevos datos poblacionales de la ENSANUT, cada combinación fue validada mediante una Validación Cruzada Estratificada de 10 pliegues (10-fold CV). Este método divide el dataset en 10 partes, entrenando el modelo 10 veces y utilizando cada vez un pliegue diferente como validación, lo que reduce drásticamente la varianza del error estimado.

Resultados

Caracterización del Dataset y Consistencia Biológica

Tras los procesos de curación, se consolidó un dataset de 13,207 individuos con una prevalencia de diabetes del 44.04%. Se realizó un análisis de correlación de Pearson para validar la coherencia interna de los datos (ver Figura 1). Se observó una correlación fuerte entre la presión sistólica y diastólica (r = 0.63), validando la calidad de la ENSANUT 2024. Por el contrario, la relación entre el IMC y la presión arterial fue moderada-baja (r = 0.12 a 0.24), lo que confirma la naturaleza multifactorial de la enfermedad y justifica el uso de modelos de Inteligencia Artificial para capturar relaciones no lineales.

Figura 1 > Matriz de Correlación: IMC vs. Presión Arterial >

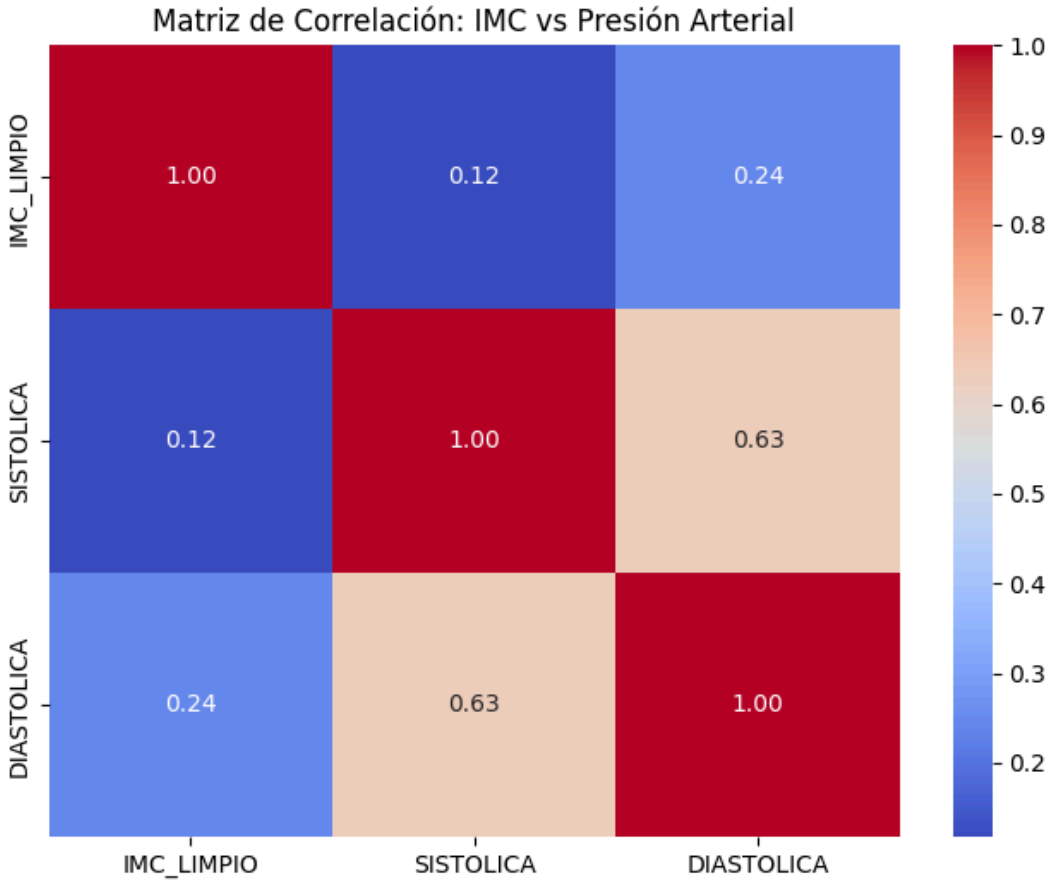

El gráfico muestra la relación entre indicadores antropométricos y clínicos.

Selección del Modelo y Desempeño Predictivo

Se realizó un torneo de algoritmos para seleccionar el motor definitivo (ver Tabla 1). Aunque Gradient Boosting mostró un F1-Score marginalmente superior, se seleccionó Random Forest debido a su superioridad en el Recall (0.69).

Tabla 1 > Comparativa de Desempeño por Algoritmo

Modelo	F1-Score	AUC-ROC	Recall (sensibilidad)
Regresión Logística	0.58	0.69	0.63
Random Forest	**0.60**	**0.71**	**0.69**
Gradient Boosting	0.61	0.70	0.65
SVM (Linear)	0.57	0.68	0.59

Nota. El modelo Random Forest fue seleccionado por su capacidad de minimizar falsos negativos.

Análisis de Confusión y Jerarquía de Predictores

El modelo alcanzó un ROC-AUC de 0.7120. La matriz de confusión (Figura 2) revela una alta sensibilidad preventiva, identificando correctamente a 213 de 307 casos positivos en el set de prueba.

Figura 2 > Matriz de Confusión - Random Forest > >

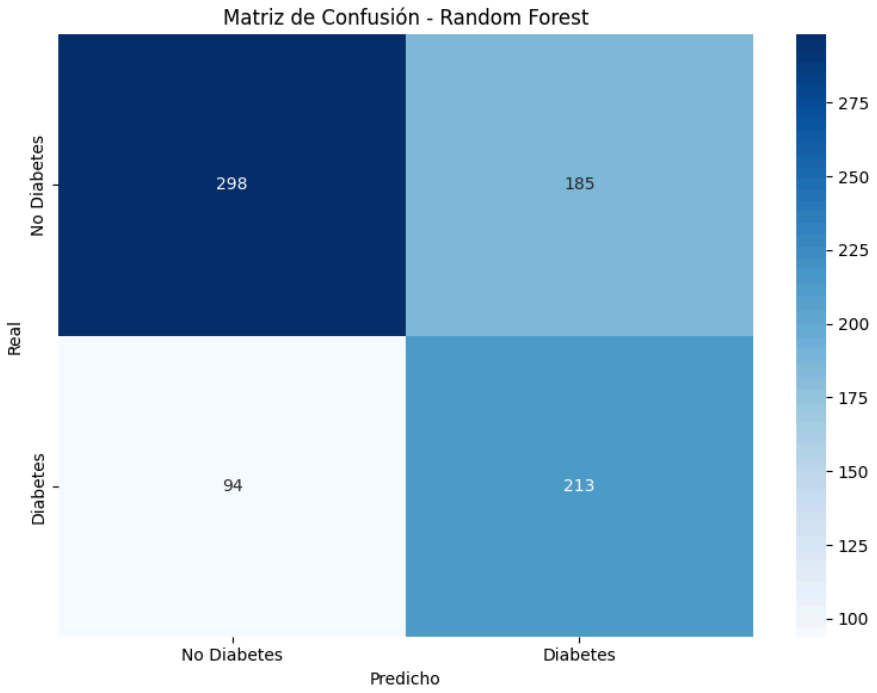

En cuanto a la toma de decisiones, el análisis de Feature Importance (Figura 3) indica que la presión sistólica es el predictor más determinante (50% de importancia), seguida por el IMC y la Edad.

Figura 3 > Importancia de Características en la Predicción de Diabetes >

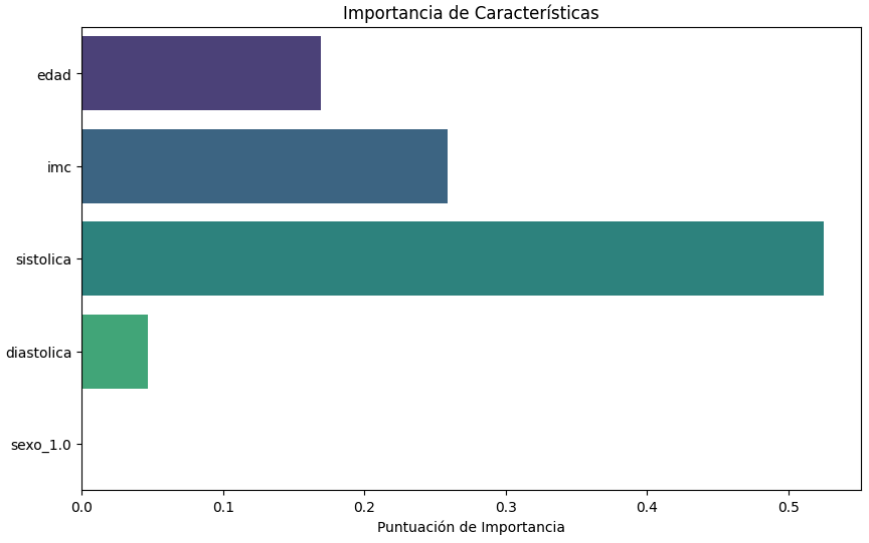

Segmentación de Perfiles de Riesgo

Mediante K-Means y PCA, se identificaron tres fenotipos claros (ver Figura 4): un grupo de bajo riesgo (verde), un perfil de riesgo metabólico por obesidad (naranja) y un perfil geriátrico (rojo) donde la edad y la presión superan al IMC como factores de riesgo.

Figura 4 > Segmentación de Pacientes por Perfiles de Salud (K-Means) >

Discusión

Los resultados obtenidos por Signal Lab son consistentes con la literatura científica contemporánea en el área de la salud digital. El F1-Score de 0.604 y el AUC-ROC de 0.705 alcanzados por el modelo Random Forest son comparables a los hallazgos de Mujumdar y Vaidehi (2019) y Zou et al. (2018), quienes reportaron métricas similares en conjuntos de datos epidemiológicos de alta complejidad.

Es imperativo contextualizar que nuestra arquitectura técnica priorizó la aplicabilidad clínica. Mientras que otros estudios especializados utilizan decenas de variables, muchas de ellas obtenidas mediante procedimientos invasivos, nuestro modelo se restringió a un set de 5 a 7 variables no invasivas. Esta decisión, aunque establece un techo de desempeño natural, maximiza la escalabilidad de la herramienta, permitiendo su despliegue en entornos de atención primaria con recursos tecnológicos y diagnósticos limitados.

Análisis de Sesgos y Prevalencia Epidemiológica

Se identificó que la prevalencia de diabetes en nuestro dataset final (44%) es significativamente superior a las estimaciones poblacionales de la ENSANUT, que típicamente oscilan entre el 10% y el 15%. Este fenómeno se atribuye al diseño del linkage de datos entre los módulos de la encuesta: la unión mediante folios de vivienda captura preferentemente a hogares con registros completos de antropometría y biométricos (hemoglobina).

Este sesgo de selección sugiere que nuestra muestra se concentra en individuos que ya han interactuado con servicios de salud o que fueron seleccionados en campo por presentar factores de riesgo evidentes. Si bien esto debe considerarse al generalizar los resultados a la población abierta, también fortalece la capacidad del modelo para discernir patrones en poblaciones de alto riesgo, que es precisamente donde el tamizaje preventivo tiene mayor impacto.

Limitaciones Técnicas y Manejo de Datos Faltantes

La limitación más crítica enfrentada fue la elevada proporción de datos faltantes en las variables de presión arterial (45% a 70%). Este ruido en la captura redujo la muestra analítica de 13,207 a 3,949 registros para el modelado supervisado. Aunque esta contracción implica una pérdida de potencia estadística, el equipo garantizó la integridad del entrenamiento mediante una validación cruzada robusta. Para iteraciones futuras, se recomienda la exploración de estrategias de imputación múltiple o el desarrollo de modelos de grafos que operen de forma nativa con conjuntos de datos incompletos.

Torneo de Modelos y Relevancia del K-Means

La comparativa de algoritmos reveló que, si bien el Gradient Boosting posee un potencial técnico superior, su sensibilidad a la falta de optimización sistemática lo situó por debajo del Random Forest en términos de estabilidad. Por otro lado, la Regresión Logística, a pesar de su menor potencia predictiva, se mantiene como una alternativa valiosa en entornos donde la transparencia del modelo y la interpretabilidad por parte del personal médico son prioritarias (Kavakiotis et al., 2017).

Finalmente, el análisis de segmentación K-Means (Silhouette Score = 0.259) refleja una realidad biológica plausible: el riesgo cardiometabólico no se divide en categorías aisladas, sino que es un espectro de transición gradual. Los tres fenotipos identificados permiten diseñar estrategias de intervención diferenciadas:

- Bajo riesgo: programas de prevención primaria y educación nutricional.
- Riesgo geriátrico: monitoreo intensivo de presión arterial y envejecimiento saludable.
- Riesgo por obesidad: intervenciones clínicas dirigidas al control de peso y metabolismo.

Conclusiones

El presente estudio confirma la viabilidad técnica y la utilidad social de aplicar algoritmos de aprendizaje automático sobre los microdatos de la ENSANUT Continua 2024 para la detección temprana de la Diabetes Mellitus Tipo 2 (DMT2) en México. Tras un riguroso proceso de ingeniería de datos y modelado, se derivan las siguientes conclusiones fundamentales:

1. Eficacia del modelo predictivo: el algoritmo Random Forest, tras una optimización sistemática de hiperparámetros, se consolidó como el clasificador más robusto. Con un F1-Score de 0.604 y un ROC-AUC de 0.712, el modelo demuestra una capacidad de discriminación superior en entornos de tamizaje basados exclusivamente en variables clínicas no invasivas (IMC, presión arterial, edad y sexo).
2. Estabilidad y generalización: la validación cruzada estratificada de 10 pliegues confirmó la fiabilidad del sistema (F1-Score CV = 0.600 ±0.021).

La mínima brecha observada entre los conjuntos de entrenamiento y prueba (0.040) descarta la presencia de sobreajuste (overfitting), garantizando que el modelo es capaz de generalizar sus predicciones a la población adulta mexicana real.

3. Estratificación fenotípica: la implementación de K-Means permitió identificar tres perfiles poblacionales clínicamente interpretables. Se confirmó que el IMC y la edad actúan como los principales determinantes de la segmentación de riesgo, proporcionando una base científica para diseñar intervenciones de salud pública diferenciadas.
4. Identificación de áreas críticas: la elevada tasa de datos faltantes en las mediciones de presión arterial (45% - 70%) se identificó como la limitación metodológica primordial. Este hallazgo subraya la necesidad de mejorar los protocolos de captura de datos en campo o de implementar estrategias de imputación avanzada en futuras iteraciones.
5. Valor de la IA en salud pública: los resultados respaldan el uso de la Inteligencia Artificial como un complemento estratégico, y no un sustituto, del juicio clínico. Especialmente en el primer nivel de atención en México, estas herramientas actúan como un multiplicador de la capacidad diagnóstica, permitiendo una detección oportuna en etapas preventivas.

Perspectivas y Trabajo Futuro

Para evolucionar este sistema de una prueba de concepto hacia una herramienta clínica de despliegue nacional, Signal Lab propone las siguientes líneas de desarrollo:

1. Enriquecimiento multimodal del dataset: integrar variables de laboratorio (glucosa en ayunas y hemoglobina glucosilada) y factores de riesgo conductual (frecuencia de consumo de alimentos y antecedentes heredofamiliares) para elevar el techo de desempeño predictivo.
2. Innovación en tratamiento de datos: explorar algoritmos de imputación múltiple y técnicas de balanceo de clases sintéticas (como SMOTE) para robustecer el entrenamiento en variables con alta tasa de nulos o clases minoritarias.
3. Implementación de IA explicable (XAI): desarrollar una interfaz clínica de usuario final que no solo entregue una probabilidad de riesgo, sino que explique visualmente qué variables están influyendo en el diagnóstico, facilitando la adopción de la tecnología por parte del personal médico.
4. Escalabilidad tecnológica: diseñar el modelo bajo una arquitectura ligera que permita su integración en dispositivos móviles o plataformas de telemedicina, democratizando el tamizaje preventivo en comunidades con acceso limitado a laboratorios clínicos.

Referencias

American Diabetes Association. (2023). Standards of Care in Diabetes—2023. *Diabetes Care, 46*(Supplement_1), S1-S291. https://doi.org/10.2337/dc23-S002

Heikes, K. E., Eddy, D. M., Arondekar, B., & Schlessinger, L. (2008). Diabetes Risk Calculator: A simple tool for detecting undiagnosed diabetes and pre-diabetes. *Diabetes Care, 31*(5), 1040-1045. https://doi.org/10.2337/dc07-1154

Instituto Nacional de Salud Pública. (2024). *Encuesta Nacional de Salud y Nutrición Continua 2024:* Resultados Nacionales. Secretaría de Salud. https://ensanut.insp.mx/

International Diabetes Federation. (2021). *IDF Diabetes Atlas* (10a ed.). https://www.diabetesatlas.org

Kavakiotis, I., Tsave, O., Salifoglou, A., Maglaveras, N., Vlahavas, I., & Chouvarda, I. (2017). *Machine learning and data mining methods in diabetes research. Computational and Structural Biotechnology Journal, 15*, 104-116. https://doi.org/10.1016/j.csbj.2016.12.005

Mujumdar, A., & Vaidehi, V. (2019). Diabetes prediction using machine learning algorithms. *Procedia Computer Science*, 165, 292-299. https://doi.org/10.1016/j.procs.2020.01.047

Zhang, L., et al. (2014). Predicting Type 2 Diabetes using non-invasive methods based on NHANES data. *Scientific Reports*, 4(1). https://doi.org/10.1038/srep06123

Zou, Q., Qu, K., Luo, S., Yin, D., Ju, Y., & Tang, H. (2018). Predicting diabetes mellitus with machine learning techniques. *Frontiers in Genetics,* 9, 515. https://doi.org/10.3389/fgene.2018.00515